

TITANIC SURVIVAL CLASSIFICATION

Dokumentacija predmetnog projekta

Softverski algoritmi u sistemima automatskog upravljanja

Fakultet tehničkih nauka, Novi Sad

1. Opis problema

Ovaj projekat bavi se binarnom klasifikacijom, odnosno predviđanjem da li je putnik preziveo brodolom Titanika (*survived* = 1) ili nije (*survived* = 0), na osnovu demografskih, porodicnih i putnih karakteristika.

Rec je o binarnoj klasifikaciji, jer postoje tacno dve moguće izlazne vrednosti. Model uci na osnovu poznatih podataka i pokusava da generalizuje obrasce, tj. da na osnovu naucenih pravilnosti tacno predvidi ishod za nove, nevidjene primere.

Dataset koriscen u projektu je *Titanic dataset* koji sadrzi informacije o 891 putniku. U nastavku je prikazan detaljan opis obrade ovog skupa podataka.

2. Pregled dataseta

Dataset (train.csv) sadrzi sledece kolone:

Kolona	Tip	Opis
PassengerId	Numericki	Jedinstveni identifikator putnika
Survived	Binarni (0/1)	Ciljna promenljiva: 0 = nije preziveo, 1 = preziveo
Pclass	Kategorijski (1/2/3)	Klasa karte - indikator socio-ekonomskog statusa
Name	Tekstualni	Puno ime putnika + titula
Sex	Kategorijski	Pol putnika (m / f)
Age	Numericki	Starost u godinama (ponekad decimalna vrednost)
SibSp	Numericki	Broj brace i sestara/supruznika na brodu
Parch	Numericki	Broj roditelja/dece na brodu
Ticket	Tekstualni	Broj karte
Fare	Numericki	Cena karte u britanskim funtama
Cabin	Tekstualni	Broj kabine
Embarked	Kategorijski	Luka ukrcavanja: C = Cherbourg, Q = Queenstown, S = Southampton

3. Obrada podataka

3.1 Nedostajuće vrednosti

Pre treniranja modela neophodno je obraditi nedostajuće vrednosti jer većina algoritama ne može da radi sa praznim poljima. Sledeća tabela prikazuje stanje u datasetu:

Kolona	Broj praznih polja	Procenat
Age	177	~20%
Cabin	687	~77%
Embarked	2	~0.2%

Resenje:

- Age - popunjavanje medijanom po tituli

Kolona Age ima oko 20% praznih vrednosti. Umesto da koristimo globalnu medijanu svih putnika – koja bi bila oko 28 godina, koristimo medijanu grupisanu po tituli (Mr, Mrs, Miss, Master). Razlog je sto titula nosi informaciju o polu i starosti — na primer, putnici sa titulom Master su decaci pa imaju mnogo manju prosečnu starost od putnika sa titulom Mr. Ovakav pristup daje precizniju procenu starosti za svakog putnika:

- Master — oko 4-5 godina
- Miss — oko 21-22 godine
- Mrs — oko 35-36 godina
- Mr — oko 30 godina
- Other — oko 45-48 godina

- Cabin - binarna kolona Has_Cabin

Kolona Cabin ima cak 77% praznih vrednosti, sto je previse za pouzdano popunjavanje. Umesto da pokušavamo da popunimo te vrednosti, kreiramo novu binarnu kolonu Has_Cabin koja oznacava da li putnik ima podatak o kabini (1) ili ne (0). Ova informacija je korisna jer su putnici sa kabinom uglavnom bili iz visih klasa i imali su bolji pristup palubi.

- Embarked - mod

Kolona Embarked ima samo 2 prazne vrednosti, sto je zanemarljivo u odnosu na ukupan broj putnika (891). Popunjavamo ih modom — najcescom vrednoscu u koloni, koja je S (Southampton), jer je odatle krenuo najveći broj putnika.

3.2 Ekstrakcija titule iz kolone Name

Kolona Name sadrzi puno ime putnika, npr. 'Braund, Mr. Owen Harris'. Samo ime nema prediktivnu vrednost za model. Medjutim, titula (Mr., Mrs., Miss., Master.) nosi korisnu informaciju o polu, godinama i drustvenom statusu putnika.

Ideja je da iz imena izvlacimo titulu i grupisemo retke titule u kategoriju Other. Rezultat je nova kolona Title sa vrednostima: Mr, Mrs, Miss, Master, Other.

3.3 Feature Engineering - novi atributi

Pored obrade postojećih kolona, kreiramo i nove attribute koji mogu biti korisni za model:



- Family_Size = SibSp + Parch + 1 - ukupna velicina porodice ukljucujuci i samog putnika
- Is_Alone - binarna kolona koja oznacava da li putnik putuje sam (Family_Size == 1)

3.4 Uklanjanje nepotrebnih kolona

Iz dataseta su uklonjene kolone koje nemaju uopste, ili nemaju znacajan uticaj na prezivljavanje ljudi na Titaniku. Ime putnika, broj karte i identifikacioni broj putnika nece ni na koji nacin uticati na *survival rate* tog putnika.

Sto se tice oznake kabine u kojoj se putnici nalaze, na modelu Random Forest uradjena je ekstrakcija ove kolone, ali model se nije poboljsao. Razlog za to jeste cinjenica da je 77% kolone *Cabin* prazno, odnosno veci broj putnika nema podatke o kabini nego broj putnika koji ima. Originalni pristup sa binarnom kolonom *Has_Cabin* se pokazao efikasnijim.

Kolona	Obrazloženje
Name	Iskoriscena samo za ekstrakciju titule
Ticket	Broj karte nema jasnu prediktivnu vrednost za prezivljavanje
Cabin	Zamenjena binarnom kolonom Has_Cabin zbog 77% praznih vrednosti
PassengerId	Samo identifikator, bez ikakve prediktivne vrednosti



3.5 Enkodovanje kategorijskih atributa

Algoritmi masinskog učenja rade isključivo sa brojevima. Zbog toga **kategorijski atributi moraju biti konvertovani u numeričke vrednosti**. Koriscena su dva različita pristupa u zavisnosti od prirode atributa:

Direktno mapiranje - Sex

Kolona *Sex* ima dve vrednosti: *male* i *female*.

Koristimo direktno mapiranje: *male* = 0, *female* = 1.

Ovaj pristup je pogodan jer postoje samo dve vrednosti i redosled nema posebno znacenje u ovom kontekstu.

One-hot encoding - Embarked i Title

Za kolone *Embarked* (S, C, Q) i *Title* (Mr, Mrs, Miss, Master, Other) koristimo **one-hot encoding** jer ne postoji prirodni redosled izmedju vrednosti. Ne mozemo samo dodeliti vrednosti S = 1, C = 2 i Q = 3, jer bi kompjuter zakljucio da je Q tri puta vece od S, sto nije smisleno u ovom kontekstu jer svaka vrednost predstavlja razlicitu kategoriju odnosno lokaciju ukrcajanja putnika.

One-hot encoding kreira novu binarnu kolonu za svaku vrednost kategorije - umesto jedne kolone *Embarked* imacemo tri zasebne kolone *Embarked_S*, *Embarked_C* i *Embarked_Q*. Zatim se izbacuje jedna od tri kolone, u ovom slucaju to je *Embarked_C*, jer je jasno da, ukoliko se putnik nije ukrcao u luci S ili Q, znamo da se ukrcao u C.

Pclass - ostavljamo kao broj

Kolona *Pclass* (1, 2, 3) ostaje kao broj jer redosled ovde ima smisao - klasa 1 je 'bolja' od klase 2 i 3 u smislu položaja na brodu i pristupa palubi.

3.6 Skaliranje podataka

Neki algoritmi su osetljivi na skalu atributa jer rade na osnovu rastojanja izmedju podataka. Na primer, atribut *Fare* koji moze ici do 500 bi dominirao nad atributom *Pclass* koji ima vrednosti 1-3, sto nije ispravno.

Za sledece modele primenjujemo *StandardScaler* standardizaciju, gde je srednja vrednost = 1 i standardna devijacija = 0:

- KNN — radi na osnovu euklidskog rastojanja
- SVM — radi na osnovu granice odlucivanja u prostoru atributa
- Logistic Regression — osetljiva na skalu zbog optimizacije parametara

Modeli zasnovani na stablima (Random Forest, Decision Tree, Gradient Boosting) i Naive Bayes nisu osetljivi na skalu atributa, pa za njih skaliranje nije potrebno.


3.7 Exploratory Data Analysis

Eksplorativna analiza podataka **EDA** se koristi za **vizuelno istraživanje podataka pre modeliranja**, dakle radi se pre treniranja modela. Služi da se bolje upoznamo sa datasetom i razumemo kako izgledaju podaci, kakve su raspodele, koji atributi su povezani sa ciljem...

- **Korelaciona mapa**

Služi da vizualizuje *Pearsonov koeficijent korelacije* izmedju svih numerickih atributa u datasetu. Vrednosti se kreću od -1 do 1, gde 1 predstavlja savršenu pozitivnu korelaciju, 0 govori da nema linearne veze i -1 predstavlja savršenu negativnu korelaciju. Otkriva koji atributi i koliko uticu na ciljnu varijablu odnosno *survival*.

Analiza korelacione mape pokazuje da je *Sex* – pol - najjaci prediktor za prezivljavanje, zatim *Pclass* – visa klasa znaci veca sansa za prezivljavanje i *Fare* – skuplja karta takodje znaci veca sansa za prezivljavanje. Kolona *Age* – godine – koeficijent je blizu 0 dakle skoro da ne postoji linearna veza izmedju godina i prezivljavanja.



4. Modeli klasifikacije

Implementirano je i upoređeno 7 različitih modela klasifikacije.

Svi modeli su trenirani i evaluirani pod istim uslovima – korisčna je ista podela podataka (*80% trening, 20% test, random_state = 42*) i iste evaluacione metrike.

4.1 Random Forest

Random Forest je kombinacija metoda zasnovana na većem broju stabala odlučivanja. Svako stablo se trenira na drugacijem podskupu podataka, a konačna predikcija se dobija glasanjem većine stabala. Slučajnost u izboru podataka i atributa čini stabla međusobno različitim, što smanjuje varijansu modela. Model sa većim brojem stabala $n_estimators = 200$ je davao malo losije rezultate, pa je ipak izabran broj stabala $n_estimators = 100$.

4.2 Decision Tree

Stablo odlučivanja deli podatke kroz niz pitanja nad atributima. Svaki unutrašnji čvor predstavlja pitanje, svaka grana predstavlja ishod, a svaki list konačnu predikciju. Parametar $max_depth = 5$ ograničava dubinu stabla i sprečava overfitting.

4.3 Gradient Boosting

Gradient Boosting sekvencijalno gradi model dodavanjem stabala odlučivanja, gde svako sledeće stablo ispravlja greske prethodnog. Za razliku od *Random Forest*-a gde stabla nastaju paralelno i nezavisno, ovde svako stablo zavisi od prethodnog, što čini metodu osetljivijom na hiperparametre. Vrednosti parametara su $n_estimators = 100$ – broj stabala i $learning_rate = 0.1$ – predstavlja udeo koliko svako novo stablo utice na konačnu predikciju.

4.4 KNN (K-Nearest Neighbors)

KNN klasifikuje novi podatak na osnovu klase njegovih K najbližih suseda u prostoru atributa. Novi podatak dobija klasu koju ima većina od K najbližih suseda. *KNN* je osetljiv na skalu atributa jer radi na osnovu rastojanja, pa se za ovaj model koristi skaliranje podataka.

Vrednost parametra najbližih suseda je $n_neighbors = 7$.

4.5 SVM (Support Vector Machine)

SVM pronalazi granicu odlučivanja sa najvećom marginom između klasa. Potporni vektori su uzorci najbliži granici i oni određuju njen položaj. Kernel funkcija omogućava *SVM*-u da formira nelinearnu granicu odlučivanja. Parametar $kernel = rbf$ (*radial basis function*) – rešava problem kad podaci nisu linearno razdvojivi i $C = 1.0$ - kontrolise kaznu za greske — veće C znači da je uza margina.

4.6 Logistic Regression

Model računa verovatnoću pripadnosti klasi koristeći logističku funkciju (sigmoid), koja vrednosti preslikava u opseg $[0, 1]$. Ako je verovatnoća veća od 0.5, predikcija je klasa 1 (preživeo). *Logistic Regression* je jedan od najjednostavnijih klasifikacionih modela i koristi se kao baseline. Parametar $max_iter = 1000$ - maksimalan broj iteracija.

4.7 Naive Bayes

Naive Bayes je klasifikator zasnovan na Bajesovoj teoremi verovatnoće. Za svaki novi podatak racuna verovatnocu pripadnosti svakoj klasi na osnovu atributa i dodeljuje klasu sa najvećom verovatnoćom. '*Naive*' naziv dolazi od pretpostavke da su svi atributi međusobno nezavisni. *GaussianNB* pretpostavlja da su vrednosti atributa normalno raspodeljene.

4.8 Grid Search optimizacija hiperparametara

Nakon što su svi modeli trenirani sa početnim vrednostima hiperparametara, primenjen je *Grid Search* kako bi se pronašle bolje vrednosti. *Grid Search* sistematski isprobava sve kombinacije zadatih vrednosti hiperparametara i bira kombinaciju koja daje najbolje rezultate na cross-validaciji.

Evaluacija je vršena sa **5-fold cross-validacijom**, što znači da se skup podataka deli na 5 delova i model se trenira i testira 5 puta. Na ovaj način se dobija pouzdanija procena performansi modela nego kada bi se koristila samo jedna podela podataka. Model *Naive Bayes* nema hiperparametre koji bi mogli da se podesavaju, pa nema smisla raditi *Grid Search* za njega.

5. Evaluacija modela

5.1 Evaluacione metrike

Za evaluaciju modela koriscene su sledece metrike:

Metrika	Formula	Znacenje
Tacnost (Accuracy)	$(TP + TN) / \text{ukupno}$	Udeo svih tacnih predikcija
Preciznost (Precision)	$TP / (TP + FP)$	Od svih predvidjenih kao preziveo, koliko je zaista prezivelo
Odziv (Recall)	$TP / (TP + FN)$	Od svih koji su prezivali, koliko je model tacno identifikovao
F1-skor	$2 * (P * R) / (P + R)$	Harmonijska sredina preciznosti i odziva

5.2 Rezultati svih modela + Grid Search rezultati


Model	Tacnost	Preciznost	Odziv	F1-skor
Random Forest	84.92%	82.19%	81.08%	81.63%
Gradient Boosting (GS)	84.92%	83.10%	79.73%	81.38%
Gradient Boosting	84.36%	83.82%	77.03%	80.28%
Decision Tree	83.80%	80.82%	79.73%	80.27%
KNN	83.80%	80.82%	79.73%	80.27%
Logistic Regression	83.24%	79.73%	79.73%	79.73%
Logistic Regression (GS)	82.68%	79.45%	78.38%	78.91%
KNN (GS)	82.12%	78.38%	78.38%	78.38%
Random Forest (GS)	82.68%	81.16%	75.68%	78.32%
SVM	82.12%	80.00%	75.68%	77.78%
SVM (GS)	82.12%	80.00%	75.68%	77.78%
Decision Tree (GS)	81.56%	80.60%	72.97%	76.60%
Naive Bayes	76.54%	70.51%	74.32%	72.37%

Od svih testiranih modela, *Random Forest* je postigao najbolje rezultate sa tačnošću od 84.92% i F1 skorom od 81.63%. Iako *Gradient Boosting (GS)* postiže istu tačnost, *Random Forest* ima viši odziv (81.08% naspram 79.73%), što znači da uspešnije identifikuje preživle putnike.

Zbog toga je *Random Forest* izabran kao **najbolji model** u ovom poređenju.

5.4 Matrice konfuzije

Za svaki model generisana je matrica konfuzije koja prikazuje odnos izmedju stvarnih i predvidjenih klasa.




Matrica konfuzije za najbolji model – Random Forest

6. Analiza rezultata

6.1 Vaznost atributa (Feature Importance)


Feature importance pokazuje koji atributi su najznacajni za donošenje odluke u modelu. Ova analiza je dostupna samo za modele zasnovane na stablima (*Random Forest*, *Decision Tree*, *Gradient Boosting*).



Feature Importance – Random Forest


Na osnovu feature importance grafika *Random Foresta*, najvazniji atributi su:

- *Fare* (cena karte) — najveći uticaj, direktno povezana sa klasom i položajem na brodu
- *Age* (starost) — mladi putnici, posebno deca, imali su prednost pri evakuaciji
- *Title_Mr* (titula) — indirektno kodira pol i starost putnika
- *Sex* (pol) — zene su imale prioritet pri evakuaciji
- *Pclass* (klasa karte) — putnici više klase imali su bolji pristup palubi



Feature Importance – Gradient Boosting

Na osnovu feature importance grafika *Gradient Boosting*, najvazniji atributi su titula, cena karte, klasa karte i starost putnika.




Feature Importance – Decision Tree

Na osnovu feature importance grafika *Decision Tree*, najvazniji atributi su takodje titula, cena karte, klasa karte i starost putnika.


6.2 Graficki prikazi odnosa atributa i prezivljavanja

Sledeci grafici su generisani tokom EDA analize i sluze kao potvrda modela kod kojih je odredjena vaznost atributa.




Preživljavanje u odnosu na titulu

Sa ovog grafika se vidi da je titula – koja je usko povezana sa polo mi starosti – imala vazan uticaj u uspesnosti prezivljavanja putnika. Titule vezane za zene imale su znatno vecu uspesnost.




Preživljavanje u odnosu na cenu karte

Medijana cene karata kod ljudi koji su preziveli je nekoliko puta veća od putnika koji nisu preziveli.




Preživljavanje po polu

Zene su imale znatno veće šanse preživljavanja u odnosu na muškarce.



Preživljavanje u odnosu na klasu karte

Putnici prve klase preživljavali su cesce od putnika trece klase. Ovo je ocekivano jer su kabine vise klase bile blize palubi, sto je omogucavalo brzi pristup camcima za spasavanje.



Raspodela starosti putnika i odnos preživelih

Mladi putnici, posebno deca, imali su vece sanse preživljavanja. Vidljivo je da je medju putnicima koji su preživeli veci udeo mladjih osoba.

6.3 Zakljucak

Rezultati pokazuju da je *Random Forest* postigao najbolje rezultate sa tacnoscu od 84.92% i F1-skorom od 81.63%.

Kljucni faktori koji uticu na preživljavanje:

- Pol - zene su imale znacajno vece sanse preživljavanja
- Klasa karte - visa klasa, vece sanse
- Starost - deca su imala prednost pri evakuaciji
- Cena karte -visoka korelacija sa klasom i polozejem na brodu

7. Preporuke za dalje unapredjenje

Na osnovu sprovedene analize, predlazu se sledece pravce za potencijalno poboljsanje modela:

7.1 Unapredjenje obrade podataka

- Ekstrakcija grupe putnika iz kolone Ticket - putnici sa istim brojem karte putuju zajedno, sto moze biti koristan atribut
- Ekstrakcija deka iz kolone Cabin (slovo kabine = dek broda) - iako se eksperimentisalo sa ovim pristupom, rezultati nisu bili bolji zbog visokog procenta nedostajucih vrednosti (~77%)
- Kreiranje dodatnih atributa iz kombinacije postojećih

7.2 Napredni algoritmi

XGBoost ili LightGBM - napredniji Gradient Boosting algoritmi koji cesto daju bolje rezultate

7.3 Poboljsanje evaluacije

Cross-validacija umesto jedne podele train/test - daje stabilniju procenu performansi, posebno korisno za male skupove podataka

7.4 Vise podataka

Najznacajnije poboljsanje bi donelo prosirenje dataseta. Sa vise podataka, svi modeli bi imali vise materijala za učenje i generalizaciju, sto bi dovelo do boljih rezultata.