

TITANIC SURVIVAL CLASSIFICATION

Dokumentacija predmetnog projekta

Softverski algoritmi u sistemima automatskog upravljanja

Fakultet tehničkih nauka, Novi Sad

Sadržaj

1. Opis problema	3
2. Pregled dataseta	3
3. Obrada podataka	4
3.1 Nedostajuce vrednosti	4
3.2 Ekstrakcija titule iz kolone Name	5
3.3 Novi atributi	5
3.4 Uklanjanje nepotrebnih kolona	5
3.5 Enkodovanje kategorijskih atributa	6
3.6 Skaliranje podataka	6
3.7 Exploratory Data Analysis	7
4. Detekcija Anomalija	10
4.1 IQR metoda	10
4.2 Isolation Forest	10
4.3 Odluka o anomalijama	11
5. Modeli klasifikacije	12
5.1 Random Forest	12
5.2 Decision Tree	12
5.3 Gradient Boosting	12
5.4 KNN (K-Nearest Neighbors)	12
5.5 SVM (Support Vector Machine)	12
5.6 Logistic Regression	12
5.7 Naive Bayes	12
6. Metodologija evaluacije i podesavanje hiperparametara	13
6.1 Princip podele podataka	13
6.2 Grid Search + Cross-Validacija	13
7. Finalni rezultati	15
7.1 Matrica konfuzije	15
8. Odabir najznacajnijih atributa	16
8.1 Poredjenje – svi atributi VS najbitnijih 6 atributa	16
9. Deployment modela	18
9.1 Export modela	18
9.2 Streamlit aplikacija (UI)	18
10. Zakljucak i preporuke za dalje unapredjenje	19
10.1 Kljucni faktori prezivljavanja	19
10.2 Kvalitet modela	19
10.3 Preporuke za dalje unapredjenje	19

1. Opis problema

Projekat bavi se binarnom klasifikacijom, odnosno predviđanjem da li je putnik preziveo brodolom Titanika (*survived* = 1) ili nije (*survived* = 0), na osnovu demografskih, porodicnih i putnih karakteristika.

Rec je o binarnoj klasifikaciji, jer postoje tacno dve moguće izlazne vrednosti. Model uci na osnovu poznatih podataka i pokusava da generalizuje obrasce, tj. da na osnovu naucenih pravilnosti tacno predvidi ishod za nove, nevidjene primere.

Projekat prati sledece faze: preprocesiranje podataka, eksplorativna analiza (EDA), detekcija anomalija, odabir i treniranje vise modela klasifikacije, podesavanje hiperparametara, analiza i odabir najznacajnijih atributa, i na kraju deployment finalnog modela kroz jednostavnu UI aplikaciju.

Skup podataka koriscen u projektu je *Titanic dataset* koji sadrzi informacije o 891 putniku. U nastavku je prikazan detaljan opis obrade ovog skupa podataka.

2. Pregled dataseta

Dataset (train.csv) sadrzi sledece kolone:

Kolona	Tip	Opis
PassengerId	Numericki	Jedinstveni identifikator putnika
Survived	Binarni (0/1)	Ciljna promenljiva: 0 = nije preziveo, 1 = preziveo
Pclass	Kategorijski (1/2/3)	Klasa karte - indikator socio-ekonomskog statusa
Name	Tekstualni	Puno ime putnika + titula
Sex	Kategorijski	Pol putnika (m / f)
Age	Numericki	Starost u godinama (ponekad decimalna vrednost)
SibSp	Numericki	Broj brace i sestara/supruznika na brodu
Parch	Numericki	Broj roditelja/dece na brodu
Ticket	Tekstualni	Broj karte
Fare	Numericki	Cena karte u britanskim funtama
Cabin	Tekstualni	Broj kabine
Embarked	Kategorijski	Luka ukrcavanja: C = Cherbourg, Q = Queenstown, S = Southampton

3. Obrada podataka

3.1 Nedostajuće vrednosti

Pre treniranja modela neophodno je obraditi nedostajuće vrednosti jer većina algoritama ne može da radi sa praznim poljima. Sledeća tabela prikazuje stanje u datasetu:

Kolona	Broj praznih polja	Procenat
Age	177	~20%
Cabin	687	~77%
Embarked	2	~0.2%

Resenje:

- Age - popunjavanje medijanom po tituli

Kolona Age ima oko 20% nedostajucih vrednosti. Umesto da koristimo globalnu medijanu svih putnika – koja bi bila oko 28 godina, koristimo medijanu grupisanu po tituli (Mr, Mrs, Miss, Master). Razlog je sto titula nosi informaciju o polu i starosti — na primer, putnici sa titulom Master su decaci pa imaju mnogo manju prosečnu starost od putnika sa titulom Mr. Ovakav pristup daje precizniju procenu starosti za svakog putnika:

- Master — oko 4-5 godina
- Miss — oko 21-22 godine
- Mrs — oko 35-36 godina
- Mr — oko 30 godina
- Other — oko 45-48 godina

- Cabin - binarna kolona Has_Cabin

Kolona Cabin ima cak 77% nedostajucih vrednosti, sto je previse za pouzdano popunjavanje. Umesto da pokusavamo da popunimo te vrednosti, kreiramo novu binarnu kolonu Has_Cabin koja oznacava da li putnik ima podatak o kabini (1) ili ne (0). Ova informacija je korisna jer su putnici sa kabinom uglavnom bili iz visih klasa i imali su bolji pristup palubi.

- Embarked - mod

Kolona Embarked ima samo 2 nedostajuće vrednosti, sto je zanemarljivo u odnosu na ukupan broj putnika (891). Popunjavamo ih modom — najcescom vrednoscu u koloni, koja je S (Southampton), jer je odatle krenuo najveći broj putnika.

3.2 Ekstrakcija titule iz kolone Name

Kolona *Name* sadrži puno ime putnika, npr. 'Braund, Mr. Owen Harris'. Samo ime nema prediktivnu vrednost za model. Međutim, titula (Mr., Mrs., Miss., Master.) nosi korisnu informaciju o polu, godinama i društvenom statusu putnika.

Ideja je da iz imena izvlacimo titulu i grupisemo retke titule u kategoriju Other.

Rezultat je nova kolona Title sa vrednostima: Mr, Mrs, Miss, Master, Other.

3.3 Novi atributi

Pored obrade postojećih kolona, kreiramo i nove attribute koji mogu biti korisni za model:

- `Family_Size = SibSp + Parch + 1` - ukupna velicina porodice ukljucujuci i samog putnika
- `Is_Alone` - binarna kolona koja oznacava da li putnik putuje sam (`Family_Size == 1`)

3.4 Uklanjanje nepotrebnih kolona

Iz dataseta su uklonjene kolone koje nemaju uopste, ili nemaju znacajan uticaj na prezivljavanje ljudi na Titaniku. Ime putnika, broj karte i identifikacioni broj putnika nece ni na koji nacin uticati na *survival rate* tog putnika.

Sto se tice oznake kabine u kojoj se putnici nalaze, na modelu Random Forest uradjena je ekstrakcija ove kolone, ali model se nije poboljsao. Razlog za to jeste cinjenica da je 77% kolone *Cabin* prazno, odnosno veci broj putnika nema podatke o kabini nego broj putnika koji ima. Originalni pristup sa binarnom kolonom *Has_Cabin* se pokazao efikasnijim.

Kolona	Obrazlozenje
Name	Iskoriscena samo za ekstrakciju titule
Ticket	Broj karte nema jasnu prediktivnu vrednost za prezivljavanje
Cabin	Zamenjena binarnom kolonom Has_Cabin zbog 77% praznih vrednosti
PassengerId	Samo identifikator, bez ikakve prediktivne vrednosti

3.5 Enkodovanje kategorijskih atributa

Algoritmi masinskog učenja rade isključivo sa brojevima. Zbog toga **kategorijski atributi moraju biti konvertovani u numeričke vrednosti**. Koriscena su dva različita pristupa u zavisnosti od prirode atributa:

Direktno mapiranje - Sex

Kolona *Sex* ima dve vrednosti: *male* i *female*.

Koristimo direktno mapiranje: *male* = 0, *female* = 1.

Ovaj pristup je pogodan jer postoje samo dve vrednosti i redosled nema posebno znacenje u ovom kontekstu.

One-hot encoding - Embarked i Title

Za kolone *Embarked* (S, C, Q) i *Title* (Mr, Mrs, Miss, Master, Other) koristimo **one-hot encoding** jer ne postoji prirodni redosled izmedju vrednosti. Ne mozemo samo dodeliti vrednosti S = 1, C = 2 i Q = 3, jer bi kompjuter zakljucio da je Q tri puta vece od S, sto nije smisleno u ovom kontekstu jer svaka vrednost predstavlja razlicitu kategoriju odnosno lokaciju ukrcajanja putnika.

One-hot encoding kreira novu binarnu kolonu za svaku vrednost kategorije - umesto jedne kolone *Embarked* imacemo tri zasebne kolone *Embarked_S*, *Embarked_C* i *Embarked_Q*. Zatim se izbacuje jedna od tri kolone, u ovom slucaju to je *Embarked_C*, jer je jasno da, ukoliko se putnik nije ukrcao u luci S ili Q, znamo da se ukrcao u C.

Isti princip primenjen je i na kolonu *Title* sa pet kategorija (Mr, Mrs, Miss, Master, Other) — kreirane su cetiri kolone (*Title_Mr*, *Title_Mrs*, *Title_Miss*, *Title_Other*), dok je kategorija *Master* izostavljena kao referentna.

Pclass - ostavljena kao broj

Kolona *Pclass* (1, 2, 3) ostaje kao broj jer redosled ovde ima smisao - klasa 1 je 'bolja' od klase 2 i 3 u smislu položaja na brodu i pristupa palubi.

3.6 Skaliranje podataka

Neki algoritmi su osetljivi na skalu atributa jer rade na osnovu rastojanja izmedju podataka. Na primer, atribut *Fare* koji moze ici do 500 bi dominirao nad atributom *Pclass* koji ima vrednosti 1-3, sto nije ispravno.

Za sledece modele primenjujemo *StandardScaler* standardizaciju, gde je srednja vrednost = 0 i standardna devijacija = 1:

- *KNN* — radi na osnovu euklidskog rastojanja
- *SVM* — radi na osnovu granice odlucivanja u prostoru atributa
- *Logistic Regression* — osetljiva na skalu zbog optimizacije parametara

Modeli zasnovani na stablima (*Random Forest*, *Decision Tree*, *Gradient Boosting*) i *Naive Bayes* nisu osetljivi na skalu atributa, pa za njih skaliranje nije potrebno.

3.7 Exploratory Data Analysis


Eksplorativna analiza podataka EDA se koristi za **vizuelno istraživanje podataka pre modeliranja**. Služi da se bolje upoznamo sa skupom podataka i razumemo kako izgledaju podaci, kakve su raspodele, koji atributi su povezani sa ciljem...

- **Korelaciona mapa**


Služi da vizualizuje *Pearsonov koeficijent korelacije* izmedju svih numerickih atributa u datasetu. Vrednosti se kreću od -1 do 1, gde 1 predstavlja savršenu pozitivnu korelaciju, 0 govori da nema linearne veze i -1 predstavlja savršenu negativnu korelaciju.

Otkriva koji atributi i koliko uticu na ciljanu varijablu odnosno *survival*.

Analiza korelacione mape pokazuje da je *Sex* – pol - najjači prediktor za preživljavanje, zatim *Pclass* – viša klasa znači veća šansa za preživljavanje i *Fare* – skuplja karta također znači veća šansa za preživljavanje. Kolona *Age* – godine – koeficijent je blizu 0 dakle skoro da ne postoji linearna veza izmedju godina i preživljavanja.




Korelaciona mapa atributa




Preživljavanje u odnosu na titulu

Sa ovog grafika se vidi da je titula – koja je usko povezana sa polom i staroscu – imala vazan uticaj u uspesnosti prezivljavanja putnika. Titule vezane za zene imale su znatno vecu uspesnost.




Prezivljavanje u odnosu na cenu karte

Medijana cene karata kod ljudi koji su preziveli je nekoliko puta veca od putnika koji nisu preziveli.




Prezivljavanje po polu

Zene su imale znacajno vecu sanse prezivljavanja u odnosu na muskarce.



Preživljavanje u odnosu na klasu karte

Putnici prve klase preživljavali su cesce od putnika trece klase. Ovo je ocekivano jer su kabine vise klase bile blize palubi, sto je omogucavalo brzi pristup camcima za spasavanje.



Raspodela starosti putnika i odnos prezivelih

Mladi putnici, posebno deca, imali su vece sanse preživljavanja. Vidljivo je da je medju putnicima koji su preziveli veci udeo mladjih osoba.

4. Detekcija Anomalija

Za detekciju anomalija primenjene su dve metode detekcije: statisticka IQR metoda i algoritamski pristup Isolation Forest.

4.1 IQR metoda

Interquartile Range IQR metoda obelezava kao anomaliju svaku vrednost koja je daleko ispod prvog ili iznad treceg *kvartila*.

Atribut	Normalan opseg	Broj otkrivenih anomalija
Age	[-6.69, 64.81]	11
Fare	[-26.72, 65.63]	116
Family_Size	[-0.50, 3.50]	91

Zakljucuje se da kolona *Fare* ima najvise anomalija jer su cene karata izuzetno neravnomerno rasporedjene.


U koloni *Family Size* obelezen je velik broj anomalija jer ova promenljiva ima mali brojevni opseg – sto pokazuje da *IQR* metoda ima mane tokom rada sa diskretnim atributima sa malim opsezima vrednosti.

4.2 Isolation Forest

Isolation Forest je algoritam koji izoluje tacke kroz nasumicne podele po atributima. Tacke koje se lako izoluju smatraju se anomalijama. Za razliku od *IQR* metode, posmatra vise atributa istovremeno.

Primenom ovog algoritma otkriveno je 45 anomalija od 891 putnika, sto iznosi 5.1%. Izabrana vrednost parametra *contamination* = 0.05.

Najcesce anomalije vezane su ponovo za *Family Size* kod porodica sa velikim brojem clanova, kao i *Fare* zbog putnika sa veoma visokim cenama karata.



Detekcija anomalija algoritmom Isolation Forest

4.3 Odluka o anomalijama

Odluceno je da se detektovane anomalije **ne uklanjaju iz dataseta**.

Ekstremne vrednosti u koloni *Fare* najcesce odgovaraju putnicima prve klase visokog imovinskog stanja, sto je stvaran i koristan signal za predikciju prezivljavanja, a ne greska u podacima. Uklanjanje ovih putnika bi smanjilo dataset i moglo bi da ukloni bas one primere koji najjasnije pokazuju vezu izmedju imovnog stanja i prezivljavanja.

Mnogoclane porodice (npr. Andersson, Goodwin, Sage) takodje nisu greska u podacima - to su stvarni putnici sa stvarno velikim brojem dece i rodjaka na brodu. Njihova "neobicnost" ukazuje na to da su velike porodice iz trece klase uglavnom **stradale** u potpunosti, dok su manje, imucnije porodice imale vece sanse. Uklanjanje ovih putnika bi modelu oduzelo bas te informativne, ali stvarne primere.

U oba slucaja, anomalije ovde ne predstavljaju greske u merenju ili unosu podataka, vec **legitimne, ekstremne, ali tacne** vrednosti koje nose koristan signal za klasifikaciju.

5. Modeli klasifikacije

Implementirano je i upoređeno 7 različitih modela klasifikacije.

5.1 Random Forest

Random Forest je kombinacija metoda zasnovana na većem broju stabala odlučivanja. Svako stablo se trenira na drugacijem podskupu podataka, a konacna predikcija se dobija glasanjem vecine stabala. Slucajnost u izboru podataka i atributa cini stabla medjusobno razlicitim, sto smanjuje varijansu modela.

5.2 Decision Tree

Stablo odlučivanja deli podatke kroz niz pitanja nad atributima. Svaki unutrasnji cvor predstavlja pitanje, svaka grana predstavlja ishod, a svaki list konacnu predikciju.

5.3 Gradient Boosting

Gradient Boosting sekvencijalno gradi model dodavanjem stabala odlučivanja, gde svako sledece stablo ispravlja greske prethodnog. Za razliku od *Random Forest*-a gde stabla nastaju paralelno i nezavisno, ovde svako stablo zavisi od prethodnog, sto cini metodu osetljivijom na hiperparametre.

5.4 KNN (K-Nearest Neighbors)

KNN klasifikuje novi podatak na osnovu klasa njegovih *K najblizih suseda* u prostoru atributa. Novi podatak dobija klasu koju ima vecina od *K najblizih suseda*. *KNN* je osetljiv na skalu atributa jer radi na osnovu rastojanja, pa se za ovaj model koristi skaliranje podataka.

5.5 SVM (Support Vector Machine)

SVM pronalazi granicu odlučivanja sa najvećom marginom izmedju klasa. Potporni vektori su uzorci najblizi granici i oni odredjuju njen položaj. Kernel funkcija omogucava *SVM*-u da formira nelinearnu granicu odlučivanja.

5.6 Logistic Regression

Model racuna verovatnocu pripadnosti klasi koristeci logisticku funkciju (sigmoid), koja vrednosti preslikava u opseg $[0, 1]$. Ako je verovatnoca veca od 0.5, predikcija je klasa 1 (preziveo). *Logistic Regression* je jedan od najjednostavnijih klasifikacionih modela i koristi se kao baseline.

5.7 Naive Bayes

Naive Bayes je klasifikator zasnovan na Bajesovoj teoremi verovatnoce. Za svaki novi podatak racuna verovatnocu pripadnosti svakoj klasi na osnovu atributa i dodeljuje klasu sa najvećom verovatnocom. 'Naive' naziv dolazi od pretpostavke da su svi atributi medjusobno nezavisni. *GaussianNB* pretpostavlja da su vrednosti atributa normalno raspodeljene.

6. Metodologija evaluacije i podesavanje hiperparametara

6.1 Princip podele podataka

Da bi procena modela bila pouzdana i da test rezultat zaista odrazavao sposobnost modela da generalizuje na nove, nevidjene podatke, primenjena je sledeca procedura:


- **Trening skup (80%)** koristi se za podesavanje hiperparametara i poredjenje modela
- **Test skup (20%)** se ne dira sve do kraja - koristi se samo jednom, za finalnu procenu vec izabranog modela

Razlog za ovakav pristup je sprecavanje **curenja informacija** (data leakage) - da test skup ne bi uticao na izbor modela ili parametara, cime bi finalni rezultat bio neopravdano optimistican. Test skup tako ostaje potpuno "nevidljiv" sve do trenutka kada je model vec konacno izabran, sto daje realnu sliku njegove performanse na podacima koje nikada nije video.

6.2 Grid Search + Cross-Validacija

Za svaki od 7 modela primenjen je **Grid Search sa 5-fold cross-validacijom** - sistematicno se isprobavaju sve kombinacije unapred definisanih hiperparametara, a svaka kombinacija se ocenjuje prosekom od 5 cross-validacionih iteracija na trening skupu. Na ovaj nacin se za svaki model pronalaze njegovi optimalni hiperparametri, a modeli se medjusobno porede na osnovu njihovih najboljih (vec podesenih) verzija.

Model	CV F1-skor	Najbolji hiperparametri
Random Forest	0.7700	max_depth=5, min_samples_split=2, n_estimators=100
SVM	0.7685	C=0.1, kernel=linear
Logistic Regression	0.7674	C=10, solver=lbfgs
Gradient Boosting	0.7543	learning_rate=0.1, max_depth=3, n_estimators=200
KNN	0.7461	metric=euclidean, n_neighbors=5
Decision Tree	0.7377	max_depth=3, min_samples_leaf=1, min_samples_split=2
Naive Bayes	0.7318	var_smoothing=1e-09



Cross-Validation poredjenje modela

Najbolji model na osnovu Cross-Validacije je *Random Forest* sa podesenim hiperparametrima: max_depth = 5.


7. Finalni rezultati

Model *Random Forest* (max_depth=5, n_estimators=100, min_samples_split=2) je nakon izbora evaluiran na test skupu. Ovo predstavlja realnu procenu sposobnosti modela da generalizuje na potpuno nevidjenim podacima.

Metrika	Vrednost	Znacenje
Tacnost	82.68%	Udeo svih tacnih predikcija
Preciznost	81.16%	Pouzdanost pozitivnih predikcija
Odziv	75.68%	Udeo pronadjenih stvarno prezivelih
F1-skor	78.32%	Harmonijska sredina preciznosti i odziva

7.1 Matrica konfuzije

Za svaki model generisana je matrica konfuzije koja prikazuje odnos izmedju stvarnih i predvidjenih klasa.




Matrica konfuzije za najbolji model – *Random Forest*

8. Odabir najznacajnijih atributa

Primenjene su dve nezavisne metode za odredjivanje znacajnosti atributa:

- Random Forest feature importance - model tokom treniranja racuna koliko je svaki atribut doprineo smanjenju neuredjenosti u stablima
- Mutual Information - statisticka metoda koja meri koliko informacije atribut nosi o ciljnoj promenljivoj, nezavisno od modela



Feature Selection modela – poredjenje RF i MI


Obe metode se u velikoj meri slazu — *Title_Mr*, *Sex*, *Fare*, *Pclass* i *Title_Mrs/Miss* su medju najznacajnijim atributima po obe metode, sto potvrđuje pouzdanost nalaza.

8.1 Poredjenje – svi atributi VS najbitnijih 6 atributa

Da bi se proverilo da li je manji skup atributa dovoljan, model *Random Forest* sa *optimalnim hiperparametrima* je treniran i evaluiran i sa svih 15 atributa i sa samo top 6 najznacajnijih atributa (*Title_Mr*, *Sex*, *Fare*, *Pclass*, *Title_Mrs*, *Age*).

Poredjenje je izvršeno isključivo na trening skupu putem 5-fold cross-validacije - test skup nije koriscen, kako bi se izbeglo njegovo ponovno "trosenje" pre finalnog izbora atributa.

Skup atributa	Tacnost	Preciznost	Odziv	F1
Svi atributi	83.56%	81.39%	73.11%	77.00%
Top 6 atributa	81.17%	81.31%	65.31%	72.22%



Poredjenje – svi atributi VS top 6 atributa

Model sa svim atributima daje bolje rezultate, posebno po odzivu (73.11% naspram 65.31%), sto znaci da model sa manje atributa propusta znatno vise stvarno prezivelih putnika. Finalni model je zadrzan sa kompletnim skupom od 15 atributa.

9. Deployment modela

Finalni model je nakon evaluacije ponovo istreniran na celokupnom datasetu (svih 891 putnika) - buduci da je njegova ocekivana performansa vec utvrdjena na test skupu, treniranje na svim raspolozivim podacima dodatno poboljsava model koji se realno koristi.

9.1 Export modela

Model je sacuvan u joblib formatu, zajedno sa listom naziva i redosleda atributa koje model ocekuje, kako bi se obezbedila konzistentnost prilikom predikcije novih podataka.

9.2 Streamlit aplikacija (UI)

Za jednostavno koriscenje modela razvijena je interaktivna web aplikacija pomocu Streamlit biblioteke. Korisnik unosi podatke o putniku (*klasu karte, pol, starost, broj clanova porodice na brodu, cenu karte, luku ukrcavanja, posedovanje kabine, opciono ime za ekstrakciju titule*), a aplikacija prikazuje predikciju (*preziveo / nije preziveo*) zajedno sa verovatnocom.

Pokretanje aplikacije:

```
uv run python src/export_model.py
uv run streamlit run app/streamlit_app.py
```

The screenshot shows a Streamlit web application with a dark theme. It features several input fields for user data: 'Ime i prezime (opciono)' with the value 'Smith, Mrs. Lesley' and a 'Press Enter to apply' button; 'Broj braca/supruznika na brodu' with a value of 2; 'Klasa karte' with a value of 1; 'Broj roditelja/dece na brodu' with a value of 2; 'Pol' with a value of 'female'; 'Cena karte (GBP)' with a value of 500.00; 'Starost' with a slider set to 31; and 'Luka ukrcavanja' with a dropdown menu set to 'Q'. There is also an unchecked checkbox for 'Putnikima dodeljenu kabinu'. A red button labeled 'Predvidi prezivljavanje' is positioned below the inputs. At the bottom, a green box displays the prediction: '✓ Putnik bi VEROVATNO PREZIVEO (verovatnoca prezivljanja: 73.4%)'. A small note at the very bottom states: 'Napomena: predikcija je zasnovana na istorijskim podacima i koristi se iskljucivo u edukativne svrhe.'

Slikovni prikaz Streamlit aplikacije za predikciju prezivljanja

10. Zaključak i preporuke za dalje unapredjenje

10.1 Ključni faktori prezivljanja

- Pol - žene su imale znatno veće šanse prezivljanja
- Titula (Title_Mr) - indirektno kodira pol i društveni status
- Cena karte i klasa - viša klasa i viša cena karte, veće šanse prezivljanja
- Starost - deca su imala prednost pri evakuaciji

10.2 Kvalitet modela

Finalni model (*Random Forest*) postize tačnost od 82.68% i F1-skor od 78.32% na potpuno nevidjenom test skupu. Razlike između modela su relativno male (*Random Forest*, *SVM* i *Logistic Regression* imaju CV F1-skor u rasponu 0.767-0.770), što ukazuje na to da je problem dostigao **prirodnu granicu performansi** za dati skup atributa i veličinu dataseta.

10.3 Preporuke za dalje unapredjenje

- Prosirenje dataseta - najveći potencijal za poboljšanje, modeli su ograničeni sa svega 891 primerom
- Napredniji ansambl algoritmi (XGBoost, LightGBM)
- Kombinovanje modela (stacking/voting ansambl od najboljih pojedinačnih modela)